



SORBONNE UNIVERSITÉ

UE : RITAL

Traitement automatique du langage

Projet TAL

Projet de traitement automatique du langage

Étudiants :

Binôme 1

Nom : BERRAIS

Prénom : wafaa

Numéro étudiant : 21516323

Binôme 2

Nom : MOHAMMEDI

Prénom : zineddine

Numéro étudiant : 21519626

Année universitaire 2025–2026

March 29, 2026

Table des matières

1	Classification des sentiments	3
1.1	Description du jeu de données	3
1.2	Analyse exploratoire des données	4
1.3	Prétraitement et préparation des données	7
1.4	Résultats expérimentaux	7
1.5	Discussion des résultats	10
2	Classification des présidents	11
2.1	Description du jeu de données	11
2.2	Analyse exploratoire des données	12
2.2.1	Analyse des documents	12
2.2.2	Analyse de la longueur des phrases	13
2.2.3	Analyse lexicale	15
2.2.4	Analyse des documents mixtes et des frontières	15
2.2.5	Synthèse de l'analyse exploratoire	16
2.3	Résultats expérimentaux	17
2.4	Résultats expérimentaux	19
2.5	Discussion des résultats	21

Table des figures

1	Répartition des classes dans le corpus de critiques de films.	4
2	Distribution du nombre de mots par critique.	5
3	Comparaison du nombre de mots par classe à l'aide d'un boxplot.	5
4	Mots les plus fréquents dans les critiques positives et négatives.	6
5	Nuages de mots des critiques positives et négatives.	6
6	Répartition des classes dans le corpus présidentiel.	12
7	Répartition des documents selon leur composition (Chirac seul, Mitterrand seul, ou mixte).	13
8	Distribution du nombre de phrases par document.	13
9	Distribution du nombre de mots par phrase selon la classe.	14
10	Comparaison du nombre de mots par classe à l'aide d'un boxplot.	14
11	Mots les plus fréquents dans les phrases de Chirac et de Mitterrand.	15
12	Nuages de mots des phrases de Chirac et de Mitterrand.	15
13	Distribution de la proportion de phrases Chirac dans les documents mixtes.	16
14	Distribution du nombre de transitions de locuteur ($C \leftrightarrow M$) par document mixte.	16

29 mars 2026

Introduction

Ce projet s’inscrit dans le cadre de l’unité d’enseignement **RITAL** et porte sur deux tâches de classification en traitement automatique du langage. L’objectif général est d’étudier, comparer et améliorer plusieurs approches de classification supervisée sur des corpus textuels de nature différente, en mettant en évidence l’impact des choix de représentation, de modélisation et de stratégie expérimentale sur les performances obtenues.

La première tâche concerne la **classification des sentiments** à partir de critiques de films issues du corpus **movies1000**. Il s’agit d’attribuer à chaque critique une polarité *positive* ou *négative*. Cette tâche permet d’explorer des méthodes variées, depuis les modèles classiques fondés sur TF-IDF jusqu’aux modèles Transformer spécialisés, en passant par des variantes adaptées aux textes longs et des méthodes d’ensemble.

La seconde tâche porte sur la **classification de phrases présidentielles**, avec pour objectif d’attribuer chaque phrase à **Jacques Chirac** ou **François Mitterrand**. Ce problème présente des difficultés spécifiques, notamment un fort déséquilibre de classes, la présence de documents mixtes et l’importance du contexte discursif local. Il constitue ainsi un cadre intéressant pour évaluer des approches contextuelles plus fines.

Dans les deux parties, notre démarche suit la même logique : analyser les données, construire des baselines, tester plusieurs familles de modèles, comparer leurs performances, puis identifier les limites des approches retenues afin de proposer des améliorations ciblées. Ce rapport présente l’ensemble de cette démarche expérimentale ainsi que les principaux résultats obtenus.

1 Classification des sentiments

1.1 Description du jeu de données

Pour la tâche de classification des sentiments, nous avons utilisé le corpus **movies1000**, constitué de critiques de films annotées selon leur polarité. Le corpus est organisé en deux répertoires principaux : un dossier **pos**, contenant les critiques positives, et un dossier **neg**, contenant les critiques négatives. Chaque fichier texte correspond à une critique individuelle et reçoit une étiquette binaire : P pour une critique positive et N pour une critique négative.

Lors du chargement des données, chaque fichier a été lu dans son intégralité puis représenté sous la forme d’un exemple composé de trois attributs principaux : un identifiant de document, son label et le texte brut associé. Cette organisation permet d’exploiter aussi bien des modèles classiques de classification de texte que des modèles plus avancés de type Transformer.

Le corpus contient au total 2000 documents, répartis de manière parfaitement équilibrée entre les deux classes, avec 1000 critiques positives et 1000 critiques négatives. Cet équilibre constitue un avantage important pour l'apprentissage supervisé, car il limite le risque de biais en faveur d'une polarité particulière et facilite l'interprétation des métriques de performance.




FIGURE 1 – Répartition des classes dans le corpus de critiques de films.

1.2 Analyse exploratoire des données

Une analyse exploratoire a été réalisée afin de mieux comprendre la structure du corpus avant l'entraînement des modèles. Cette étape a permis d'examiner plusieurs caractéristiques importantes, notamment la longueur des critiques, leur variabilité, ainsi que certaines tendances lexicales selon la polarité.

Le tableau 1 présente les principales statistiques descriptives du corpus. On observe que la longueur moyenne des critiques est de 746.34 mots, avec une médiane de 696.50 mots. L'écart entre la longueur minimale (17 mots) et la longueur maximale (2678 mots) met en évidence une forte hétérogénéité dans la taille des documents. Cette variabilité est importante dans le cadre de la classification automatique, en particulier pour les modèles Transformer, dont la longueur d'entrée est généralement limitée.

Mesure	Valeur
Nombre total de documents	2000
Nombre de documents positifs	1000
Nombre de documents négatifs	1000
Longueur moyenne (mots)	746.34
Longueur médiane (mots)	696.50
Longueur minimale (mots)	17
Longueur maximale (mots)	2678

TABLE 1 – Statistiques descriptives du corpus `movies1000`.

L'étude des longueurs montre que les critiques présentent une forte dispersion en nombre de mots. Une partie des documents est relativement courte, tandis qu'une autre partie est beaucoup plus longue et détaillée. Cette observation est particulièrement importante dans le cadre de l'utilisation de modèles Transformer, car ces derniers imposent gé-

néralement une longueur maximale en nombre de tokens. Une critique trop longue risque donc d’être tronquée, ce qui peut entraîner une perte d’information utile, notamment lorsque l’opinion globale de l’auteur apparaît plutôt à la fin du texte.

La distribution globale des longueurs, présentée dans la figure 2, montre que la majorité des critiques se concentre autour de longueurs intermédiaires, tout en laissant apparaître une queue de distribution vers les textes les plus longs.




FIGURE 2 – Distribution du nombre de mots par critique.

Afin de comparer plus finement les longueurs selon la polarité, nous avons également représenté la distribution du nombre de mots par classe à l’aide d’un boxplot. La figure 3 montre que les critiques positives et négatives présentent des profils globalement comparables en termes de longueur, avec des médianes proches et la présence de nombreuses valeurs extrêmes dans les deux groupes.




FIGURE 3 – Comparaison du nombre de mots par classe à l’aide d’un boxplot.

Une analyse lexicale simple a également été effectuée à partir des mots les plus fréquents dans chaque classe, après suppression des mots vides les plus courants. Cette étape permet d'identifier certaines tendances générales dans le vocabulaire utilisé. Les critiques positives font davantage apparaître des termes associés à l'appréciation du film, à la qualité perçue ou à l'engagement du spectateur. À l'inverse, les critiques négatives mettent plus souvent en avant des mots liés à l'échec du film, à la faiblesse du scénario, au manque d'intérêt ou à une appréciation défavorable de la réalisation.




FIGURE 4 – Mots les plus fréquents dans les critiques positives et négatives.

Pour compléter cette analyse, nous avons également généré des nuages de mots pour chaque polarité. Bien que ces représentations soient moins quantitatives que les graphiques de fréquence, elles permettent d'illustrer visuellement les différences de vocabulaire dominantes entre les deux classes. Elles mettent en évidence, de manière plus synthétique, les termes récurrents qui structurent les critiques positives et négatives.



FIGURE 5 – Nuages de mots des critiques positives et négatives.

Dans l'ensemble, cette analyse exploratoire met en évidence trois éléments importants pour la suite du travail. Premièrement, le corpus est équilibré, ce qui constitue une base favorable pour l'apprentissage supervisé. Deuxièmement, les longueurs des documents sont très variables, ce qui peut poser des difficultés aux modèles limités en longueur d'entrée. Troisièmement, des différences lexicales apparaissent entre les deux polarités, ce qui justifie l'utilisation de représentations textuelles classiques, comme TF-IDF, ainsi que l'expérimentation de modèles contextuels plus avancés.

1.3 Prétraitement et préparation des données

Après la phase d’exploration, les données ont été préparées pour les différentes expériences de classification. Dans un premier temps, le corpus complet a été chargé sous forme tabulaire, avec pour chaque exemple son identifiant, son texte et son label. Les labels textuels ont ensuite été encodés de manière cohérente afin de faciliter l’apprentissage supervisé.

Le corpus a ensuite été séparé en ensembles d’entraînement et de validation à l’aide d’un découpage stratifié. Ce choix permet de conserver la même proportion de classes dans les deux sous-ensembles, ce qui garantit une évaluation plus fiable des modèles sur les données de validation.

Deux types de préparation ont ensuite été utilisés selon la famille de modèles considérée.

Pour les modèles classiques de machine learning, les textes ont été représentés à l’aide d’une vectorisation TF-IDF. Cette représentation transforme chaque critique en vecteur numérique fondé sur l’importance statistique des mots dans le corpus. Plusieurs variantes ont ensuite été testées, notamment à travers l’utilisation d’unigrammes et de bigrammes, ainsi que différents réglages de fréquence minimale et maximale des termes.

Pour les modèles de type Transformer, les textes ont été traités à l’aide d’un tokenizer associé au modèle pré-entraîné. Cette tokenisation convertit les critiques en séquences de tokens numériques directement exploitables par le réseau. Une contrainte importante dans ce cadre est la longueur maximale d’entrée du modèle. Lorsque la critique dépasse cette limite, elle est tronquée. Cette propriété a joué un rôle important dans l’analyse des erreurs, car certaines critiques très longues peuvent perdre une partie de leur contenu lors de cette transformation.

Ainsi, la préparation des données a été pensée de manière à être adaptée aux spécificités de chaque famille de modèles, tout en conservant une procédure expérimentale cohérente pour la comparaison finale.

1.4 Résultats expérimentaux

Nous avons mené plusieurs séries d’expériences afin d’identifier le meilleur système pour la classification des sentiments. Les modèles testés couvrent des approches complémentaires : modèles classiques sur TF-IDF, modèles à base d’embeddings, Transformers généralistes, Transformers spécialisés pour le sentiment, variantes adaptées aux textes longs et méthodes d’ensemble.

L’évaluation sur l’ensemble de validation repose sur quatre métriques : l’accuracy, la précision, le rappel et le score F1.

Expérience 1 – Baselines classiques

Nous avons d’abord testé plusieurs modèles classiques de classification de texte sur des représentations TF-IDF, notamment *Multinomial Naive Bayes*, la régression logistique et *LinearSVC*. L’objectif était d’établir une baseline simple, rapide à entraîner et solide.

Le meilleur modèle de cette première phase est **LinearSVC**, avec les performances suivantes sur validation :

- Accuracy : **0.8650**
- Précision : **0.8544**
- Rappel : **0.8800**

— F1 : **0.8670**

Expérience 2 – Amélioration du SVM

Nous avons ensuite cherché à améliorer la meilleure baseline classique en testant plusieurs variantes de représentation : **word n-grams**, **char n-grams** et **LSA**. La version retenue pour les expériences finales est un modèle TF-IDF + LinearSVC avec les hyperparamètres du tableau 2.

Hyperparamètre	Valeur retenue
ngram_range	(1, 2)
min_df	3
max_df	0.95
sublinear_tf	True
C	5.0

TABLE 2 – Configuration finale retenue pour le SVM optimisé.

Ce modèle atteint sur validation :

- Accuracy : **0.8925**
- Précision : **0.8792**
- Rappel : **0.9100**
- F1 : **0.8943**

Expérience 3 – Modèles NLP avancés

Nous avons ensuite testé plusieurs modèles plus avancés afin de comparer le SVM à des approches fondées sur des embeddings ou sur des représentations contextuelles :

- **FastText**
- **DistilBERT**
- **BERT**

Ces modèles ont été évalués dans une configuration standard de classification binaire. Les résultats obtenus restent inférieurs à ceux du meilleur SVM.

Expérience 4 – Transformer spécialisé pour le sentiment

Après les modèles généralistes, nous avons testé des modèles déjà pré-entraînés pour l’analyse de sentiment, en particulier **Twitter-RoBERTa** de CardiffNLP. Ce choix est motivé par le fait que le modèle a déjà appris à représenter des indices de polarité, ce qui peut être utile pour notre tâche.

Dans les dernières exécutions, la configuration retenue pour Twitter-RoBERTa est résumée dans le tableau 3.

Paramètre	Valeur retenue
Modèle	cardiffnlp/twitter-roberta-base-sentiment-latest
Nombre d'époques	3
Learning rate	2e-5
Warmup ratio	0.06
Weight decay	0.01
Batch size train	8
Batch size eval	16
Longueur maximale	512 tokens

TABLE 3 – Configuration retenue pour Twitter-RoBERTa.

La version standard de ce modèle atteint sur validation :

- Accuracy : **0.9075**
- Précision : **0.8826**
- Rappel : **0.9400**
- F1 : **0.9104**

Expérience 5 – Adaptation aux textes longs

L'analyse d'erreurs a montré qu'une partie des erreurs des Transformers provenait de la troncature des critiques longues. Pour répondre à cette limite, nous avons testé une stratégie **head+tail**, qui consiste à conserver à la fois le début et la fin du document.

Deux variantes ont été comparées :

- **head+tail 256/256** : 256 premiers tokens + 256 derniers tokens
- **head+tail 384/128** : 384 premiers tokens + 128 derniers tokens

Dans la même phase, nous avons également testé **DeBERTa-v3-base**, mais ce modèle n'a pas donné de résultats exploitables dans notre cadre expérimental.

Les meilleurs résultats de cette expérience sont obtenus avec **RoBERTa head+tail 256/256**, qui devient le meilleur modèle individuel.

Expérience 6 – Ensembles

Enfin, nous avons testé plusieurs méthodes d'ensemble afin de combiner la robustesse du SVM et les capacités contextuelles des Transformers.

Une première fusion simple **SVM + RoBERTa** avec seuil de confiance donne déjà un gain par rapport aux modèles pris isolément. Ensuite, une recherche plus large de combinaisons pondérées a été réalisée en intégrant :

- le **SVM optimisé**,
- **RoBERTa standard**,
- **RoBERTa head+tail 256/256**,
- **RoBERTa head+tail 384/128**.

Le meilleur ensemble trouvé sur validation est :

$$SVM(2.0) + RoBERTa_{256/256}(0.5) + RoBERTa_{384/128}(0.5)$$

avec un seuil de décision de **0.52**.

Tableau récapitulatif des résultats sur validation

Le tableau 4 synthétise les principaux résultats obtenus.

Exp.	Modèle	Accuracy	Précision	Rappel	F1
1	LinearSVC baseline	0.8650	0.8544	0.8800	0.8670
2	SVM optimisé	0.8925	0.8792	0.9100	0.8943
3	FastText	0.8675	0.8551	0.8850	0.8698
3	DistilBERT	0.8375	0.8426	0.8300	0.8363
3	BERT	0.8475	0.8062	0.9150	0.8571
4	Twitter-RoBERTa standard	0.9075	0.8826	0.9400	0.9104
5	RoBERTa head+tail 256/256	0.9425	0.9275	0.9600	0.9435
5	RoBERTa head+tail 384/128	0.9325	0.9179	0.9500	0.9337
5	DeBERTa-v3-base	0.5000	0.0000	0.0000	0.0000
6	Ensemble simple SVM + RoBERTa	0.9125	0.9146	0.9100	0.9123
6	Meilleur ensemble final	0.9650	0.9559	0.9750	0.9653

TABLE 4 – Résultats principaux obtenus sur l’ensemble de validation.

Résultats sur la plateforme

Les résultats de plateforme seront ajoutés après soumission des différents systèmes retenus. Le tableau 1.4 est laissé prêt à être complété.

Modèle soumis	Accuracy	Précision	Rappel	F1
FastText	78.088	82.618	71.144	76.453
SVM optimisé	84.300	88.512	78.832	83.392
Twitter-RoBERTa standard	91.336	88.127	95.544	91.686
RoBERTa head+tail 384/128	92.224	89.406	95.800	92.492
RoBERTa head+tail 256/256	92.640	90.799	94.896	92.802
Ensemble SVM + RoBERTa	92.516	91.073	94.272	92.645
Ensemble SVM + RoBERTa head+tail (256/256)	92.264	89.932	95.184	92.483
Meilleur ensemble final	92.944	91.350	94.872	93.077

TABLE 5 – Résultats obtenus sur la plateforme de test.

1.5 Discussion des résultats

Les expériences montrent d’abord qu’un **SVM bien réglé** constitue une baseline solide sur ce corpus, mais qu’il reste nettement en dessous des meilleures approches contextuelles. Sur la plateforme, le SVM optimisé obtient un score F1 de **83.392**, tandis que **FastText** atteint **76.453**. Les modèles **DistilBERT** et **BERT**, évalués uniquement sur validation, n’ont pas non plus permis de dépasser cette référence dans notre cadre expérimental.

Le premier gain important apparaît avec **Twitter-RoBERTa**, ce qui confirme l’intérêt d’un modèle déjà spécialisé pour l’analyse de sentiment. Ce modèle atteint un score F1 de **0.9104** sur validation et de **91.686** sur la plateforme. L’analyse d’erreurs a ensuite mis en évidence le rôle de la **troncature** sur les critiques longues. Les variantes **head+tail**

améliorent nettement les résultats, en particulier la configuration **256/256**, qui devient le meilleur modèle individuel, avec un score F1 de **0.9435** sur validation et de **92.802** sur la plateforme.

Le meilleur résultat global est obtenu avec le **meilleur ensemble final**, qui combine le SVM et deux variantes head+tail de RoBERTa. Ce système atteint un score F1 de **0.9653** sur validation et de **93.077** sur la plateforme, ce qui en fait le modèle retenu dans notre travail.

Son principal avantage est de combiner des informations complémentaires : le SVM exploite efficacement les indices lexicaux globaux, tandis que les variantes RoBERTa capturent mieux le contexte et profitent d’une meilleure couverture des textes longs. Les résultats obtenus sur la plateforme confirment globalement la hiérarchie observée sur validation : les modèles classiques restent en retrait, les modèles Transformer spécialisés sont plus performants, les variantes head+tail améliorent encore les résultats, et les méthodes d’ensemble donnent les meilleures performances finales.

La principale limite du système retenu reste son coût plus élevé en calcul et en temps d’inférence par rapport à un modèle unique, en particulier face à une solution classique comme le SVM. Il offre néanmoins le meilleur compromis entre performance et robustesse parmi toutes les approches testées.

2 Classification des présidents

2.1 Description du jeu de données

Pour la tâche de classification des présidents, nous avons utilisé un corpus de discours politiques composé de phrases prononcées par deux anciens présidents de la République française : Jacques Chirac et François Mitterrand. Le corpus est organisé sous la forme d’un fichier texte structuré, où chaque ligne correspond à une phrase individuelle annotée selon le format `<doc_id:phrase_id:label> texte`. Chaque phrase reçoit une étiquette binaire : **C** pour une phrase attribuée à Chirac et **M** pour une phrase attribuée à Mitterrand.

Lors du chargement des données, chaque ligne a été parsée à l’aide d’une expression régulière afin d’extraire quatre attributs principaux : un identifiant de document, un identifiant de phrase au sein du document, le label du locuteur et le texte brut associé. Cette organisation permet de reconstituer la structure documentaire du corpus et d’analyser les données à deux niveaux de granularité : la phrase et le document.

Un fichier de test séparé, `corpus.tache1.test`, est également fourni. Ce fichier suit le même format structuré, mais sans annotation de label, les phrases étant identifiées uniquement par leur identifiant de document et de phrase au format `<doc_id:phrase_id>`.

Contrairement au corpus de critiques de films utilisé dans la première partie, la répartition des classes est **fortement déséquilibrée**, avec 49 890 phrases de Chirac (86.9 %) contre seulement 7 523 phrases de Mitterrand (13.1 %), soit un ratio C/M de 6.63. Ce déséquilibre constitue un défi important pour l’apprentissage supervisé, car un modèle naïf pourrait obtenir une accuracy élevée en prédisant systématiquement la classe majoritaire, sans réellement capturer les caractéristiques stylistiques de chaque président.

Mesure	Valeur
Nombre total de phrases	57 413
Nombre de documents distincts	587
Phrases Chirac (C)	49 890 (86.9 %)
Phrases Mitterrand (M)	7 523 (13.1 %)
Ratio C/M	6.63
Longueur moyenne (mots)	21.54
Longueur médiane (mots)	18.00
Longueur minimale (mots)	1
Longueur maximale (mots)	386

TABLE 6 – Statistiques descriptives du corpus présidentiel (ensemble d’entraînement).




FIGURE 6 – Répartition des classes dans le corpus présidentiel.

2.2 Analyse exploratoire des données

Une analyse exploratoire a été réalisée afin de mieux comprendre la structure du corpus avant l’entraînement des modèles. Cette étape a permis d’examiner plusieurs caractéristiques importantes, notamment la composition des documents, la longueur des phrases, leur variabilité selon le locuteur, ainsi que certaines tendances lexicales propres à chaque président.

2.2.1 Analyse des documents

Une particularité importante de ce corpus est la présence de **documents mixtes**, c’est-à-dire des documents contenant à la fois des phrases de Chirac et de Mitterrand. Cette caractéristique distingue fondamentalement cette tâche d’une classification de documents classique : ici, le contexte local d’une phrase peut contenir des interventions des deux locuteurs, ce qui rend l’attribution plus difficile.

L’analyse montre que sur les 587 documents du corpus, 400 sont des documents mixtes (68.1 %), ce qui signifie que plus des deux tiers des documents contiennent des phrases des deux présidents. Dans ces documents mixtes, la proportion moyenne de phrases de Chirac est de 72.16 %, contre 27.84 % pour Mitterrand, reflétant le déséquilibre global du corpus. La figure 7 illustre la répartition des trois types de documents.




FIGURE 7 – Répartition des documents selon leur composition (Chirac seul, Mitterrand seul, ou mixte).

La distribution du nombre de phrases par document, présentée dans la figure 8, révèle une forte hétérogénéité dans la taille des documents. Certains documents ne contiennent que quelques phrases, tandis que d’autres en contiennent plusieurs dizaines.




FIGURE 8 – Distribution du nombre de phrases par document.

2.2.2 Analyse de la longueur des phrases

L’étude des longueurs des phrases montre que celles-ci présentent une dispersion notable en nombre de mots. La longueur moyenne globale est de 21.54 mots, avec une médiane de 18.00 mots et un écart-type de 14.34. L’écart entre la longueur minimale (1 mot) et la longueur maximale (386 mots) met en évidence une forte hétérogénéité.

On observe une différence de longueur entre les deux classes : les phrases de Mitterrand sont en moyenne plus longues (26.84 mots, médiane 22.00) que celles de Chirac (20.74 mots, médiane 18.00). L’écart-type est également plus élevé pour Mitterrand (19.78 contre 13.14), ce qui indique une plus grande variabilité dans la longueur de ses interventions. Cette différence pourrait refléter un style oratoire plus développé chez Mitterrand.

Mesure	Chirac (C)	Mitterrand (M)
Nombre de phrases	49 890	7 523
Longueur moyenne (mots)	20.74	26.84
Longueur médiane (mots)	18.00	22.00
Longueur minimale (mots)	1	1
Longueur maximale (mots)	386	297
Écart-type (mots)	13.14	19.78

TABLE 7 – Statistiques de longueur des phrases par classe.

La distribution du nombre de mots par phrase selon la classe, présentée dans la figure 9, montre les profils de longueur pour chaque président.




FIGURE 9 – Distribution du nombre de mots par phrase selon la classe.

La figure 10 compare ces distributions à l'aide d'un boxplot, permettant d'observer les médianes, les quartiles et les valeurs extrêmes dans chaque classe.




FIGURE 10 – Comparaison du nombre de mots par classe à l'aide d'un boxplot.

Une analyse lexicale a été effectuée à partir des mots les plus fréquents dans chaque classe, après suppression des mots vides les plus courants de la langue française. Cette étape permet d'identifier certaines tendances générales dans le vocabulaire utilisé par chaque président. Les phrases de Chirac font davantage apparaître des termes liés à certaines thématiques diplomatiques et internationales, tandis que les phrases de Mitterrand mettent plus souvent en avant un vocabulaire lié à des questions de société et de politique intérieure.



Nuage de mots - Chirac

Nuage de mots - Mitterrand

2.2.4 Analyse des documents mixtes et des frontières

15

Pour mieux comprendre la structure de ces documents, nous avons analysé la proportion de phrases de chaque président dans les documents mixtes. La figure 13 montre la distribution de la proportion de phrases Chirac au sein de ces documents.




FIGURE 13 – Distribution de la proportion de phrases Chirac dans les documents mixtes.

Nous avons également étudié les **transitions** entre locuteurs au sein de chaque document, c'est-à-dire les endroits où le label passe de C à M ou de M à C. L'analyse révèle que les 400 documents mixtes présentent en moyenne 2.00 transitions chacun, avec un maximum de 2 transitions par document. Cela signifie que chaque document mixte contient typiquement un segment de Chirac et un segment de Mitterrand, avec une ou deux frontières nettes entre les deux. Ces frontières sont particulièrement importantes car, comme nous le verrons dans l'analyse des erreurs, les phrases situées près de ces transitions sont les plus difficiles à classer correctement. La figure 14 présente la distribution du nombre de transitions par document mixte.




FIGURE 14 – Distribution du nombre de transitions de locuteur ($C \leftrightarrow M$) par document mixte.

2.2.5 Synthèse de l'analyse exploratoire

Dans l'ensemble, cette analyse exploratoire met en évidence plusieurs éléments importants pour la suite du travail. Premièrement, le corpus est **fortement déséquilibré** en faveur de Chirac (86.9 % contre 13.1 %), ce qui nécessite une attention particulière lors de l'évaluation des modèles et du choix des métriques. Deuxièmement, la présence de **400**

documents mixtes (68.1 % du corpus) constitue une difficulté majeure, car le contexte local d’une phrase peut contenir des interventions de l’autre président, ce qui peut induire le modèle en erreur. Troisièmement, les **transitions entre locuteurs** au sein des documents mixtes créent des zones de frontière où la classification est particulièrement difficile. Quatrièmement, les phrases de Mitterrand sont en moyenne **plus longues** (26.84 mots) que celles de Chirac (20.74 mots), ce qui pourrait constituer un indice discriminant. Cinquièmement, des différences lexicales apparaissent entre les deux présidents, ce qui justifie l’exploration de représentations textuelles capturant le style et le vocabulaire propre à chaque locuteur.

2.3 Résultats expérimentaux

Nous avons mené plusieurs séries d’expériences afin d’identifier la meilleure stratégie de classification pour cette tâche. Les essais réalisés couvrent plusieurs variantes de **CamemBERT-large**, avec et sans pondération des classes, ainsi qu’une analyse plus fine de l’effet du contexte et des zones de transition entre locuteurs.

L’évaluation sur l’ensemble de test local repose sur quatre métriques principales : l’accuracy, la précision, le rappel et le score F1. Dans cette partie, l’accuracy est mesurée globalement sur l’ensemble des phrases, tandis que la précision, le rappel et le F1 rapportés ci-dessous correspondent à la classe Mitterrand, qui constitue la classe minoritaire.

Expérience 1 – Baseline phrase par phrase

Nous avons d’abord préparé une baseline simple consistant à classer chaque phrase indépendamment, sans utiliser de chunks ni de fenêtres de contexte. Le modèle utilisé dans cette configuration est **CamemBERT-large**, appliqué directement aux phrases prises isolément.

Cette expérience constitue un point de comparaison important, car elle permet d’évaluer ce qu’un Transformer peut apprendre à partir du seul contenu local de la phrase, sans information supplémentaire sur son environnement discursif. .

Expérience 2 – Version corrigée avec split par document, chunks et fenêtres de contexte

Nous avons ensuite développé une version plus robuste de la méthode, fondée sur trois choix méthodologiques importants : un split par document avant toute création d’exemples, une construction de chunks homogènes en locuteur pour l’apprentissage, et une prédiction phrase par phrase à l’aide de fenêtres de contexte au moment du test local.

Dans cette configuration, le modèle est entraîné sur des chunks construits à partir de segments consécutifs appartenant au même locuteur, puis évalué sur des fenêtres contextuelles construites autour de chaque phrase cible. Sur les chunks de validation, le meilleur checkpoint obtient un score F1 macro de 98.811, une AUC de 99.947 et une Average Precision de 99.793.

Sur l’ensemble de test local, cette version constitue le meilleur système actuellement obtenu dans nos expériences. Elle atteint les performances suivantes :

- Accuracy : **0.9505**
- Précision : **0.7990**
- Rappel : **0.8426**
- F1 : **0.8203**

Le score F1 macro obtenu sur le test local est de 0.8958, ce qui confirme la bonne robustesse de cette configuration malgré le déséquilibre du corpus.

Expérience 3 – Weighted loss et early stopping

Nous avons également testé une variante introduisant un rééquilibrage de la fonction de coût, afin de mieux prendre en compte la sous-représentation de Mitterrand dans le corpus. Cette stratégie repose sur des poids de classes calculés à partir de la distribution des labels dans les chunks d’entraînement, tout en conservant un mécanisme d’early stopping.

Sur les chunks de validation, cette variante obtient un score F1 macro de 97.561, une AUC de 99.924 et une Average Precision de 99.708.

Sur le test local, les performances observées sont les suivantes :

- Accuracy : **0.9491**
- Précision : **0.8449**
- Rappel : **0.7602**
- F1 : **0.8003**

Cette variante reste donc compétitive, mais elle n’améliore pas le meilleur modèle global. Elle favorise davantage la précision sur la classe Mitterrand, au prix d’une baisse du rappel.

Expérience 4 – Variante analysée sur les frontières et les documents mixtes

Nous avons ensuite étudié une autre exécution de la méthode contextuelle afin d’analyser plus finement les erreurs dans les documents mixtes et à proximité des frontières de locuteur. Cette variante obtient sur les chunks de validation un score F1 macro de 98.038, une AUC de 99.890 et une Average Precision de 99.631.

Sur le test local, elle atteint :

- Accuracy : **0.9404**
- Précision : **0.7428**
- Rappel : **0.8503**
- F1 : **0.7929**

Cette configuration se distingue par un rappel élevé sur Mitterrand, mais sa précision plus faible entraîne une baisse des performances globales par rapport à la meilleure version corrigée.

Expérience 5 – Influence de la taille de la fenêtre de contexte

Une série d’expériences diagnostiques a ensuite été menée afin d’étudier l’impact de la taille du contexte au moment du test local, sans réentraîner le modèle. L’objectif était de vérifier si un contexte plus court pouvait être préférable dans les documents mixtes, en particulier lorsque la phrase cible se situe près d’une frontière entre locuteurs.

Parmi les tailles testées, la meilleure configuration diagnostique est obtenue avec une fenêtre de 250 mots. Cette variante atteint un score F1 macro de 89.823, une AUC de 97.673 et une Average Precision de 83.997. Pour la classe Mitterrand, elle obtient un rappel de 90.609 % et une précision de 75.957 %. Ces résultats suggèrent qu’un contexte plus court peut parfois améliorer le compromis entre rappel et robustesse dans les zones ambiguës.

Les autres tailles de fenêtre testées donnent des résultats inférieurs en F1 macro :

- 350 mots : F1 macro = 87.906

- 200 mots : F1 macro = 87.824
- 150 mots : F1 macro = 87.135
- 120 mots : F1 macro = 86.590

Expérience 6 – Test adaptatif local sur les zones critiques

Enfin, nous avons testé une stratégie adaptative locale consistant à réduire dynamiquement la taille de la fenêtre dans les documents mixtes ou à proximité des frontières de locuteur. Ce test a été conçu comme un diagnostic local, en s'appuyant sur des informations disponibles uniquement dans le test local.

Les résultats obtenus sont très faibles. La meilleure configuration de ce test adaptatif n'atteint qu'un F1 macro de 49.824, avec un rappel de 15.609 % et une précision de 13.226 % sur la classe Mitterrand. Cette approche n'a donc pas été retenue pour la suite.

Tableau récapitulatif des résultats sur test local

Le tableau 10 synthétise les principaux résultats obtenus à ce stade.

Exp.	Modèle	Accuracy	Précision	Rappel	F1
2	CamemBERT corrigé avec chunks + contexte	0.9505	0.7990	0.8426	0.8203
3	CamemBERT avec weighted loss + early stopping	0.9491	0.8449	0.7602	0.8003
4	Variante contextuelle analysée sur les frontières	0.9404	0.7428	0.8503	0.7929

TABLE 8 – Résultats principaux obtenus sur l'ensemble de test local.

Les expériences sur la taille de fenêtre et sur l'adaptation locale ont principalement une valeur diagnostique. Elles éclairent le comportement du système, mais ne constituent pas encore des modèles finaux complètement stabilisés.

2.4 Résultats expérimentaux

Nous avons mené plusieurs séries d'expériences finales comparatives afin d'identifier la meilleure stratégie de classification pour cette tâche. Les modèles testés reposent tous sur **CamemBERT-large**, mais diffèrent par la manière de construire les chunks d'entraînement et le contexte fourni au modèle au moment de la prédiction phrase par phrase.

L'évaluation repose sur deux niveaux complémentaires. D'une part, chaque expérience est suivie sur les **chunks de validation**, à l'aide de trois métriques : le F1 macro, l'AUC et l'Average Precision. D'autre part, l'évaluation principale est réalisée sur un **test local au niveau des phrases**, avec l'accuracy globale ainsi que la précision, le rappel et le score F1 pour la classe **Mitterrand**, qui constitue la classe minoritaire.

Expérience 1 – Chunks fixes 250 mots et contexte 250 mots

La première expérience repose sur une construction **fixe** des chunks d'entraînement, avec une longueur maximale de **250 mots**. Au moment du test local, chaque phrase est évaluée dans une fenêtre de contexte de **250 mots**. Cette configuration correspond à la stratégie la plus simple parmi les variantes contextuelles finales, tout en conservant un compromis satisfaisant entre richesse contextuelle et stabilité des segments.

Sur les chunks de validation, le meilleur checkpoint de cette expérience obtient les scores suivants :

- F1 macro : **96.045**
- AUC : **99.405**
- Average Precision : **97.894**

Sur le test local, cette expérience obtient :

- Accuracy : **0.9555**
- Précision (Mitterrand) : **0.8238**
- Rappel (Mitterrand) : **0.8283**
- F1 (Mitterrand) : **0.8261**

Le score F1 macro obtenu sur le test local est de **0.9003**. Cette première expérience constitue finalement la meilleure configuration globale retenue dans nos essais locaux.

Expérience 2 – Chunks fixes 350 mots et contexte 250 mots

La deuxième expérience conserve la même logique de segmentation fixe, mais augmente la longueur maximale des chunks d'entraînement à **350 mots**, tout en maintenant une fenêtre de contexte de **250 mots** au moment du test local. L'objectif était de vérifier si des segments plus longs permettaient d'améliorer la représentation du style discursif des locuteurs.

Sur les chunks de validation, cette configuration obtient :

- F1 macro : **96.351**
- AUC : **99.488**
- Average Precision : **97.774**

Sur le test local, elle atteint :

- Accuracy : **0.9566**
- Précision (Mitterrand) : **0.8497**
- Rappel (Mitterrand) : **0.8011**
- F1 (Mitterrand) : **0.8247**

Le score F1 macro sur le test local est de **0.9000**. Cette variante obtient donc une accuracy légèrement supérieure à celle de l'expérience 1, ainsi qu'une meilleure précision sur la classe Mitterrand, mais son rappel plus faible entraîne un score F1 inférieur sur cette classe.

Expérience 3 – Variante *frontier-aware* avec base 250 mots et contexte 250 mots

La troisième expérience introduit une stratégie *frontier-aware*, conçue pour mieux prendre en compte les zones proches des frontières entre locuteurs. L'idée est de construire les segments d'entraînement de manière plus sensible à la structure des documents mixtes, afin de mieux capturer les transitions entre Chirac et Mitterrand.

Sur les chunks de validation, cette configuration obtient :

- F1 macro : **94.311**
- AUC : **98.478**
- Average Precision : **96.533**

Sur le test local, elle atteint :

- Accuracy : **0.9573**
- Précision (Mitterrand) : **0.8873**
- Rappel (Mitterrand) : **0.7616**
- F1 (Mitterrand) : **0.8196**

Le score F1 macro sur le test local est de **0.8977**. Cette expérience présente la meilleure précision sur la classe Mitterrand parmi les configurations complètes, mais son rappel plus faible limite son intérêt en comparaison de l’expérience 1.

Tableau récapitulatif des résultats de validation

Le tableau 9 synthétise les performances obtenues sur les chunks de validation.

Expérience	F1 macro	AUC	Average Precision
Chunks fixes 250 mots + contexte 250 mots	96.045	99.405	97.894
Chunks fixes 350 mots + contexte 250 mots	96.351	99.488	97.774
Variante <i>frontier-aware</i> base 250 + contexte 250	94.311	98.478	96.533

TABLE 9 – Résultats obtenus sur les chunks de validation.

Tableau récapitulatif des résultats sur test local

Le tableau 10 synthétise les résultats obtenus sur le test local au niveau des phrases.

Expérience	Accuracy	Précision	Rappel	F1	F1 macro
Chunks fixes 250 mots + contexte 250 mots	0.9555	0.8238	0.8283	0.8261	0.9003
Chunks fixes 350 mots + contexte 250 mots	0.9566	0.8497	0.8011	0.8247	0.9000
Variante <i>frontier-aware</i> base 250 + contexte 250	0.9573	0.8873	0.7616	0.8196	0.8977

TABLE 10 – Résultats principaux obtenus sur le test local. La précision, le rappel et le F1 correspondent à la classe Mitterrand.

Résultats sur la plateforme

Les soumissions sur la plateforme de test sont encore en cours d’exécution au moment de la rédaction. À ce stade, le meilleur résultat observé sur la plateforme correspond à la soumission **MIND_WZ 6**, enregistrée le **18/03/2026 à 20 :01 :31**. Cette soumission obtient une précision de **78.066**, un rappel de **96.759** et un score F1 de **86.895**.

2.5 Discussion des résultats

Les expériences montrent qu’une approche contextuelle fondée sur **CamemBERT-large** est bien adaptée à cette tâche, à condition de respecter la structure documentaire du corpus grâce à un **split par document**. Parmi les configurations testées, la première expérience, avec des chunks fixes de 250 mots et un contexte de 250 mots, apparaît comme la plus équilibrée. Même si d’autres variantes obtiennent une accuracy légèrement supérieure, elle présente le meilleur compromis global, avec le meilleur F1 sur la classe Mitterrand (**0.8261**) et le meilleur F1 macro local (**0.9003**).

La deuxième expérience, avec des chunks plus longs, améliore légèrement la précision mais perd en rappel, tandis que la variante *frontier-aware* réduit certains faux positifs au prix d’une baisse plus nette du rappel. Les résultats montrent ainsi qu’une meilleure précision seule ne suffit pas si la couverture de la classe minoritaire diminue.

Enfin, les premiers résultats sur la plateforme de test confirment que le système reste compétitif. La meilleure soumission observée à ce stade, **MIND_WZ 6**, atteint un F1 de **86.895**, avec un rappel particulièrement élevé. À ce stade, la configuration 250/250 reste donc le modèle retenu, car elle offre le meilleur équilibre entre robustesse, rappel et performance globale.

Conclusion générale

Dans ce projet, nous avons étudié deux tâches de classification textuelle complémentaires : la classification des sentiments sur des critiques de films et la classification de phrases attribuées à deux présidents français. Ces deux tâches nous ont permis d’explorer plusieurs niveaux d’analyse en traitement automatique du langage, depuis les représentations lexicales classiques jusqu’aux modèles Transformer et aux méthodes d’ensemble.

Pour la **classification des sentiments**, les expériences ont montré qu’un **SVM optimisé** constitue une baseline solide, mais que les meilleurs résultats sont obtenus avec des modèles plus avancés. En particulier, **Twitter-RoBERTa** a permis un net gain de performance, encore amélioré grâce à une stratégie **head+tail** adaptée aux critiques longues. Le meilleur système retenu est finalement un **ensemble** combinant le SVM et plusieurs variantes de RoBERTa, qui obtient les meilleures performances aussi bien sur validation que sur la plateforme de test.

Pour la **classification des présidents**, les résultats montrent qu’une approche contextuelle fondée sur **CamemBERT-large** est bien adaptée à la tâche, à condition de respecter la structure documentaire du corpus. Le meilleur compromis a été obtenu avec une stratégie reposant sur des **chunks fixes de 250 mots** et une **fenêtre de contexte de 250 mots**, ce qui permet de mieux prendre en compte l’environnement discursif de chaque phrase, en particulier dans les documents mixtes.

Au-delà des résultats obtenus, ce projet met en évidence l’importance de l’**analyse exploratoire**, de l’**analyse d’erreurs** et de l’**comparaison méthodique** des expériences. Dans les deux tâches, les gains les plus intéressants ne proviennent pas uniquement du choix d’un modèle plus complexe, mais aussi d’une meilleure adaptation aux propriétés du corpus et au type de difficulté rencontré.

Plusieurs **perspectives** peuvent être envisagées pour prolonger ce travail. Pour la classification des sentiments, il serait intéressant d’explorer des architectures mieux adaptées aux **textes longs**, ainsi que des méthodes d’ensemble plus avancées ou des stratégies de calibration des probabilités. Pour la classification des présidents, des améliorations pourraient passer par une meilleure modélisation des **frontières entre locuteurs**, par l’intégration plus explicite de la structure des documents mixtes, ou encore par des stratégies d’apprentissage mieux adaptées au **déséquilibre des classes**. De manière plus générale, une validation plus robuste sur plusieurs découpages et une analyse qualitative plus approfondie des erreurs permettraient de consolider encore davantage les conclusions obtenues.